

به نام خدا



دانشگاه صنعتی شریف

گزارش پروژه درس یادگیری ماشین

نگارش

علی ابراهیمی، آمیاری سی و سه مرده، امیر پارسا جهانانی

استاد

دکتر شریفی زارچی

زمستان ۱۴۰۴

فهرست

3 Data Visualization - فاز اول
6Feature Engineering - فاز دوم
7 Learn & Estimate - فاز سوم
9 Uncertainty & Sales Classification - فاز چهارم
11 Deep - فاز پنجم

فاز اول – Data Visualization

در این فاز هدف ما این بود که قبل از هر نوع مدل‌سازی، کاملاً بفهمیم داده‌ها چه رفتاری دارند، فروشگاه‌ها چگونه عمل می‌کنند و چه متغیرهایی احتمالاً روی فروش اثر جدی دارند. به عبارتی، این مرحله برای این بود که «با داده‌ها زندگی کنیم» و رفتارشان را از نزدیک ببینیم، نه اینکه مستقیم سراغ مدل برویم.

در ادامه، تمام کارهایی که در کد انجام شده و برداشت‌هایی که از آن داشتیم، مرحله به مرحله توضیح داده می‌شود.

بارگذاری و آماده‌سازی اولیه داده‌ها

ابتدا دو فایل `train.csv` و `store.csv` خوانده شدند. فایل `train` شامل رکوردهای فروش روزانه هر فروشگاه بود و فایل `store` شامل اطلاعات ثابت مربوط به هر فروشگاه (مثل `StoreType` و اطلاعات رقابت).

ستون `Date` به فرمت `datetime` تبدیل شد تا بتوانیم ویژگی‌های زمانی استخراج کنیم و تحلیل سری زمانی انجام دهیم. سپس داده‌ها بر اساس `Date` و `Store` مرتب شدند. این کار مخصوصاً برای محاسبه `rolling` و تحلیل روند بسیار مهم است، چون اگر ترتیب زمانی به هم بخورد، میانگین‌های متحرک و تحلیل روند اشتباه می‌شود.

ستون `StateHoliday` به صورت رشته‌ای استانداردسازی شد تا مقادیر ناسازگار (مثلاً `0.0`) اصلاح شوند. همچنین اگر ستون `Open` مقدار گم‌شده داشت، با `1` پر شد (فرض اینکه فروشگاه باز بوده).

در نهایت دو جدول `train` و `store` بر اساس `Store` با هم `merge` شدند و یک دیتافریم نهایی به نام `df` ساخته شد. این دیتافریم پایه تمام تحلیل‌های بعدی بود.

ایجاد ویژگی‌های زمانی

برای اینکه رفتار فروش را بهتر بفهمیم، از ستون تاریخ ویژگی‌های زیر استخراج شد:

سال (`Year`)

ماه (`Month`)

شماره هفته (`WeekOfYear`)

روز هفته محاسبه شده (`DayOfWeek_calc`)

و یک شاخص ساده برای آخر هفته بودن (`IsWeekend`)

این ویژگی‌ها هنوز وارد مدل نشده‌اند، اما برای تحلیل روند و بررسی رفتار فروش بسیار مفید هستند.

فیلتر کردن روزهای باز

برای اینکه مقایسه‌ها عادلانه باشد، فقط روزهایی در نظر گرفته شد که فروشگاه باز بوده (`Open = 1`) و فروش بیشتر از صفر بوده است. این کار باعث شد تحلیل‌ها تحت تأثیر روزهای تعطیل کامل یا رکوردهای غیرعادی قرار نگیرند. دیتافریم `df_open` برای همین هدف ساخته شد.

دسته‌بندی فروشگاه‌ها بر اساس سطح فروش

برای اینکه تحلیل روند فقط محدود به یک فروشگاه خاص نباشد، فروشگاه‌ها بر اساس میانگین فروش روزانه دسته‌بندی شدند.

نکته مهم این است که از mean استفاده شد نه sum چون اگر از مجموع فروش استفاده کنیم، فروشگاهی که مدت بیشتری فعال بوده ممکن است صرفاً به خاطر تعداد روز بیشتر، مجموع بالاتری داشته باشد. اما میانگین روزانه معیار عادلانه‌تری است.

بر اساس صدک‌های 33٪ و 66٪، فروشگاه‌ها به سه گروه تقسیم شدند:

فروش پایین

فروش متوسط

فروش بالا

از هر گروه به صورت تصادفی 3 فروشگاه انتخاب شد تا رفتار آن‌ها بررسی شود. این کار کمک کرد تحلیل ما فقط به یک نمونه خاص محدود نشود.

تحلیل روند فروش (Trend Analysis)

برای هر گروه، فروش به صورت هفتگی تجمیع شد (resample هفتگی با مجموع فروش). سپس برای نرم‌تر شدن نمودار، میانگین متحرک سه‌هفته‌ای روی آن اعمال شد.

نتایج نشان داد:

- فروشگاه‌های گروه High سطح فروش بالاتر و نوسان بزرگ‌تری دارند.
 - فروشگاه‌های Low پایدارتر اما با دامنه کوچک‌تر هستند.
 - در همه گروه‌ها الگوی فصلی هفتگی و دوره‌های اوج و افت تکرارشونده مشاهده شد.
- همچنین یک نمودار مقایسه‌ای نرمال‌شده رسم شد. در این نمودار فروش هر فروشگاه بر میانه خودش تقسیم شد تا شکل روندها با هم مقایسه شود.

این کار نشان داد که اگرچه سطح فروش متفاوت است، اما شکل نوسان بسیاری از فروشگاه‌ها مشابه است. این موضوع نشان می‌دهد که عوامل فصلی مشترک در کل شبکه فروش وجود دارد.

بررسی اثر ویژگی‌ها بر فروش

در این بخش اثر چند متغیر کلیدی بررسی شد:

اثر Promo

میانگین و میانه فروش در حالت Promo=1 و Promo=0 محاسبه شد. همچنین boxplot رسم شد تا توزیع کامل دیده شود.

نتیجه واضح بود:

در روزهای پروموشن، میانگین فروش به شکل محسوسی بالاتر است.

نرخ uplift نسبی نیز محاسبه شد:

(میانگین فروش در - Promo=1 میانگین در Promo=0) تقسیم بر میانگین در حالت بدون پروموشن.

این عدد نشان می‌دهد پروموشن چه درصدی فروش را افزایش می‌دهد. این متغیر یکی از مهم‌ترین عوامل مدل خواهد بود.

اثر SchoolHoliday

در تعطیلات مدارس، در برخی فروشگاه‌ها فروش افزایش جزئی داشت، اما اثر آن به شدت Promo نبود. توزیع فروش در حالت SchoolHoliday=1 نسبتاً گسترده‌تر بود.

اثر StateHoliday

در تعطیلات رسمی، فروش در بسیاری از فروشگاه‌ها کاهش داشت یا رفتار متفاوتی نشان می‌داد. اما این اثر یکنواخت نبود و بستگی به نوع فروشگاه داشت.

اثر Promo بر اساس StoreType

در این قسمت بررسی شد که آیا اثر پروموشن در همه انواع فروشگاه یکسان است یا نه.

برای هر StoreType میانگین و میانه فروش در حالت Promo=0 و Promo=1 محاسبه شد و نمودار خطی رسم شد.

نتایج نشان داد:

در بعضی StoreType ها اثر Promo بسیار قوی‌تر از سایرین است.

یعنی همه فروشگاه‌ها به یک شکل به پروموشن واکنش نشان نمی‌دهند.

این نتیجه اهمیت تعامل بین StoreType و Promo را در مدل‌سازی نشان می‌دهد.

تحلیل همبستگی (Correlation Analysis)

در انتها ماتریس همبستگی بین متغیرهای عددی محاسبه شد.

نکته مهم: ستون Customers حذف شد تا data leakage رخ ندهد، چون Customers عملاً نماینده مستقیم فروش است و استفاده از آن پیش‌بینی را غیرواقعی می‌کند.

در ماتریس همبستگی مشاهده شد:

- Promo همبستگی مثبت با Sales دارد.

- برخی ویژگی‌های زمانی همبستگی متوسط دارند.

- برخی متغیرها تقریباً بی‌اثر هستند.

همچنین 15 متغیری که بیشترین همبستگی را با Sales داشتند لیست شدند. این لیست سرنخ اولیه برای مهندسی ویژگی در فاز بعدی بود.

فاز دوم - Feature Engineering

اول از همه فایل‌های train و store رو خونديم و با هم يکي کرديم. ستون تاريخ رو تبديل به datetime کرديم که بتونيم راحت ازش سال و ماه و بقيه چيزها رو استخراج کنيم. داده‌ها رو بر اساس Store و Date مرتب کرديم، چون وقتی قاره لگ و ميانگين متحرک بسازيم، اگر ترتيب زمانی درست نباشه کل فيچرها خراب می‌شن.

بعد شروع کرديم به ساختن فيچرهای زمانی. از روی تاريخ، سال، ماه، روز، شماره هفته، شماره روز سال و اين‌که آخر هفته هست يا نه رو استخراج کرديم. حتی اين‌که اول ماهه يا آخر ماه هم مشخص کرديم. اينها به مدل کمک می‌کنن بفهمه مثلاً فروش آخر ماه فرق داره يا نه، يا تابستون‌ها چه رفتاری داريم.

بعد رفتيم سراغ تعطيلات. فقط نگفتيم امروز تعطيله يا نه. يه کار قشنگ‌تر کرديم: حساب کرديم چند روز مونده تا تعطيلي بعدی و چند روز از تعطيلي قبلی گذشته. اين خیلی مهمه چون فروش معمولاً قبل تعطيلي يه رفتاری داره، بعد تعطيلي يه رفتار ديگه. اينجوری مدل می‌تونه اون موج قبل و بعد تعطيلات رو ياد بگيره.

برای اينکه فصل‌ها رو بهتر بفهمه، از سينوس و کسينوس استفاده کرديم. (Fourier terms) اين کار کمک می‌کنه مدل به شکل نرم‌تر بفهمه که سال يه سيکل داره. يعنی به جای اينکه فقط بگيم "ماه 1، ماه 2..."، يه موج پيوسته بهش می‌ديم که بتونه الگوی سالانه رو بهتر ياد بگيره.

از اطلاعات مربوط به فروشگاه هم فيچر ساختيم. مثلاً حساب کرديم رقيب از کی وارد بازار شده و چند روز از اون تاريخ گذشته. يا اينکه Promo2 تو اين ماه خاص فعاله يا نه. چون داشتن Promo2 به تنهایی کافی نيست؛ مهم اينه که اون ماه جزو بازه پرموشن باشه يا نه. حتی يه ستون ساده ساختيم که بگه فاصله تا رقيب اصلاً معلوم هست يا نه.

اما مهم‌ترين قسمت اين فاز ساخت lag و rolling بود. چون فروش امروز خیلی به فروش ديروز و هفته قبل وابسته است. برای هر فروشگاه فروش 1 روز قبل، 7 روز قبل، 14 روز قبل و 28 روز قبل رو ساختيم. بعد ميانگين و انحراف معيار متحرک 7، 14 و 28 روزه رو هم اضافه کرديم.

اينجا يه نکته خیلی مهم رعايت شد: قبل از محاسبه ميانگين متحرک، فروش رو يک روز شيفت داديم. يعنی فروش امروز تو محاسبه خودش وارد نشد. اگر اين کار رو نمی‌کرديم، مدل عملاً جواب امروز رو از خودش می‌فهميد و يه RMSE الکی عالی می‌داد. اين دقيقاً همون جاييه که خیلی‌ها اشتباه می‌کنن و بدون اينکه بفهمن داده آینده رو وارد گذشته می‌کنن.

يه فيچر ديگه هم ساختيم که ميانگين تجمعی فروش هر فروشگاه تا قبل از امروز رو نشون می‌ده. اين کمک می‌کنه مدل بفهمه سطح کلی فروش اين فروشگاه چقدره.

بعد يه تعامل ساده بين Promo و SchoolHoliday ساختيم. چون ممکنه اثر پرموشن تو تعطيلات مدرسه فرق داشته باشه. اين تعامل‌های ساده بعضی وقتا خیلی تاثيرگذار می‌شن.

ستون‌های دسته‌ای مثل نوع فروشگاه و Assortment و StateHoliday رو هم به صورت one-hot درآورديم تا مدل بتونه باهاشون کار کنه.

بعد از اينکه همه فيچرها ساخته شد، رفتيم سراغ تقسيم زمانی. 42 روز آخر رو گذاشتيم برای تست، 42 روز قبلش برای اعتبارسنجی، و بقيه رو برای آموزش. اين تقسيم کاملاً زمانی بود، نه تصادفی. چون تو سری زمانی نبايد آینده رو قاطی گذشته کرد.

پر کردن مقادیر گم‌شده رو عمداً بعد از تقسیم انجام دادیم. مدین هر ستون فقط روی train حساب شد و همون مقدار روی val و test هم اعمال شد. این کار برای این بود که هیچ اطلاعاتی از آینده وارد train نشه.

بعد ستون‌هایی که نباید وارد مدل می‌شدن حذف شدند. مهم‌ترینش Customers بود، چون تقریباً مستقیم با Sales مرتبطه و استفاده ازش باعث میشه مدل تقلبی خوب بشه.

ویژگی‌ها با StandardScaler اسکیل شدند، اما فقط فیچرها، نه Store. Store شناسه است و معنی عددی نداره که اسکیل بشه. اسکیلر فقط روی train fit شد و بعد روی val و test اعمال شد.

در آخر، خروجی نهایی ذخیره شد. فیچرها اسکیل شده هستند، Sales با log1p تبدیل شده تا توزیعش نرمال‌تر بشه و مدل راحت‌تر یاد بگیره، و ستون‌های Store و Date هم برای تحلیل‌های بعدی نگه داشته شدند.

فاز سوم - Learn & Estimate

اول کار، فایل‌های خروجی فاز ۲ یعنی train_features.csv، val_features.csv و test_features.csv رو لود کردیم و لیست ستون‌های فیچر رو هم از feature_cols.json برداشتیم. یک "هارد فیکس" هم گذاشته شد که اگر به هر دلیلی ستون Store داخل feature_cols مانده باشد، حذفش کنیم. این کار خیلی مهمه چون Store شناسه است، اگر به عنوان فیچر وارد مدل بشه، مدل ممکنه به جای یادگیری الگو، بره سمت حفظ کردن رفتار فروشگاه‌ها و نتیجه‌ها غیر واقعی خوب یا عجیب بشه. بعدش هم Date دوباره datetime شد و Store با خیال راحت به int تبدیل شد که وسط merge‌ها یا گروپ‌بندی‌ها به مشکل نخوره.

از همون اول تصمیم پروژه این بود که Sales داخل فایل‌های فاز ۲ به شکل log1p ذخیره شده (یعنی $\log(1+Sales)$). پس اینجا هر متریکی که حساب می‌کردیم، باید اول خروجی مدل و y واقعی رو برگردونیم به مقیاس اصلی. دقیقاً همین کار انجام شد: توی تابع rmse و rmspe اول np.exp(m1 * y_true - y_pred) تا برگردن به فروش واقعی، بعد metric رو حساب کردیم. حتی ماسک گذاشتیم که $y_true > 0$ باشه، چون RMSPE با صفرها مشکل داره. این باعث شد گزارش خطا واقعی و قابل اعتماد باشه، نه مصنوعی.

بعد رفتیم سراغ baseline اول: میانگین متحرک ۷ روزه. برای اینکه baseline واقعاً ساده و منصفانه باشه، مستقیم از train.csv خام استفاده کردیم. برای هر فروشگاه، فروش رو یک روز شیفت دادیم و 7 rolling mean روزه گرفتیم. یعنی پیش‌بینی امروز فقط از گذشته ساخته می‌شد. برای جاهایی که rolling موجود نبود (مثلاً اول‌های سری)، مقدار پیش‌بینی رو با میانگین فروش همان فروشگاه پر کردیم و اگر باز هم چیزی نشد، با میانگین کل پر شد. نتیجه این baseline روی validation این بود که RMSE حدود 3424.65 و RMSPE حدود 0.3030 شد. این عددها به ما گفتن اگر خیلی ساده پیش بریم، درصد خطا نسبتاً بالاست و جا برای بهتر شدن خیلی داریم.

بعد baseline دوم رو ساختم: یک مدل خطی، ولی نه با کتابخانه آماده؛ خودمون با گرادین دیسنت و ریدج (L2) پیاده‌سازی کردیم. وزن‌ها با مقدارهای کوچک تصادفی شروع شدن، آموزش به صورت mini-batch انجام شد (batch_size بزرگ برای سرعت)، و هر epoch روی validation RMSPE حساب شد. برای اینکه مدل overfit نکنه، بهترین وزن‌ها بر اساس کمترین RMSPE validation نگه داشته شد و آخر کار هم همون بهترین وزن‌ها برگردونده شد. روند آموزش هم مشخص بود که RMSPE از حدود 0.90 اول کار کم‌کم پایین اومد و بعد از چندین epoch تثبیت شد.

خروجی نهایی مدل خطی این بود که روی validation حدود 0.2248 RMSPE و روی تست حدود 0.2048 RMSPE گرفتیم. یعنی نسبت به moving average بهتر شد، ولی هنوز فاصله زیادی با یک مدل قوی‌تر داشت. این دقیقاً همون چیزی بود که انتظار داشتیم: مدل خطی وقتی فیچرهای سری‌زمانی خوبی داریم، بد نیست، اما چون رابطه‌ها تو فروش معمولاً غیرخطی و پر از interaction هست، مدل خطی یه سقف مشخص داره.

بعد برای اینکه بفهمیم مدل خطی بیشتر به چی تکیه کرده، "اهمیت ویژگی" رو با قدر مطلق وزن‌ها حساب کردیم و ۲۰ تا ویژگی برتر رو رسم کردیم. چیزی که تو نمودار خیلی واضح بود اینه که Open بیشترین وزن رو داشت و خیلی از بقیه بزرگ‌تر بود. این منطقیه چون وقتی فروشگاه بسته است، فروش عملاً نزدیک صفر می‌شه و اگر این ستون درست وارد مدل شده باشه، اثرش خیلی شدید دیده می‌شه. بعد از Open، Promo و چندتا lag مثل Sales_lag_14 و Sales_lag_7 و همچنین weekofyear و چندتا ویژگی فصلی و فروش تجمعی فروشگاه دیده می‌شدن. خلاصه‌اش این بود که مدل خطی بیشتر به سیگنال‌های خیلی مستقیم و ساده تکیه کرده.

اما بخش اصلی فاز ۳، XGBoost بود. اینجا رفتیم سراغ مدل درختی تقویتی چون معمولاً برای دیتای Rossmann خیلی خوب جواب می‌ده و می‌تونه تعامل‌ها و غیرخطی بودن‌ها رو راحت‌تر یاد بگیره. داده‌ها رو به فرم DMatrix تبدیل کردیم و یک custom metric هم نوشتیم که دقیقاً RMSPE رو روی مقیاس واقعی حساب کنه (با expm1). اینجا هم همان داستان برگرداندن از log به فروش واقعی رعایت شد.

برای تنظیم هایپرپارامترها، کد طوری نوشته شد که اگر RUN_TUNING=True باشه، گرید سرچ اجرا بشه و ترکیب‌های مختلف max_depth و eta رو امتحان کنه. اما برای اینکه اجرای پروژه طولانی و چندساعته نشه، گرید سرچ خاموش بود و از یک ترکیب از قبل انتخاب‌شده استفاده شد؛ ترکیبی که داخل همان فضای جستجو قرار داشت و گفته شده کمترین خطا را داده. پارامترهای نهایی این‌ها بودند: max_depth=8, eta=0.05, subsample=0.8, colsample_bytree=0.7, reg:squarederror هدف هم بود و eval_metric پیش‌فرض خاموش شد تا فقط همان RMSPE سفارشی معیار اصلی باشه.

مدل با early stopping آموزش داده شد. یعنی اگر روی validation بهتر نشد، ادامه نده که overfit نشه. طبق لاگ آموزش، RMSPE از مقدارهای بالا خیلی سریع پایین اومد و بعد از چندصد round، نزدیک بهترین حالت تثبیت شد. در نهایت بهترین round حدود 231 بود (تو خروجی هم مشخص بود) و مدل روی تست به RMSPE حدود 0.1111 رسید. این عدد خیلی مهمه چون یعنی XGBoost تقریباً خطا رو نسبت به مدل خطی تقریباً نصف کرد و نسبت به moving average هم خیلی بهتر شد. پس نتیجه واضح این فاز این شد که مدل درختی تقویتی با اختلاف بهترین گزینه‌ی کلاسیک ماست.

بعد از آموزش XGBoost، نمودار feature importance هم رسم شد. تو این نمودار چندتا نکته خیلی واضح بود. CompetitionDistance جزو مهم‌ترین‌ها بود، یعنی فاصله تارقیب واقعاً روی فروش اثر داشته و مدل ازش به عنوان یک سیگنال قوی استفاده کرده. بعدش Sales_lag_1 خیلی بالا بود که کاملاً طبیعی است چون فروش دیروز معمولاً بهترین پیش‌بینی برای امروز است. DayOfWeek هم جزو بالایی‌ها بود، یعنی مدل به شدت الگوی هفتگی رو یاد گرفته Sales_lag_7 و Sales_lag_14 هم بالا بودند که یعنی اثر "هفته قبل" و "دو هفته قبل" نقش پررنگی داشته. بعدش هم rolling ها مثل Sales_roll_std_7 و Sales_roll_mean_7 و همچنین Sales_cum_mean_store دیده می‌شدن که یعنی مدل هم سطح کلی فروشگاه رو می‌فهمه، هم نوسان‌های کوتاه‌مدت رو. حتی Fourier term ها (sin/cos) هم تو ۲۰ تای اول ظاهر شدند که یعنی سیگنال فصل‌ها واقعاً کمک کرده، ولی به اندازه lag ها تعیین‌کننده نبوده.

فاز چهارم - Uncertainty & Sales Classification

اول کار، دوباره خروجی های فاز ۲ رو لود کردیم (train/val/test)، لیست فیچرها رو از JSON برداشتیم و مثل قبل مطمئن شدیم ستون Store اشتباهی وارد فیچرها نشده. چون هنوز هم Store شناسه است و اگر بیاد تو مدل، خیلی راحت مدل به جای یاد گرفتن، میره سمت حفظ کردن. بعد همه train/val/test رو با هم چسبوندیم (df_all) و بر اساس Store و Date مرتب کردیم، چون تو این فاز کلی شیفت و افست داریم و اگر ترتیب درست نباشه همه چی خراب میشه.

نکته خیلی مهم این فاز اینه که چون ما پیش بینی چندروزه داریم، نمی تونیم همون split قبلی رو خام استفاده کنیم. چرا؟ چون وقتی می خوای ۷ روز جلوتر رو پیش بینی کنی، باید مطمئن باشی لیبِل (y) از آینده ی مجاز میاد و با بخش های val/test قاطی نمیشه. برای همین یک ماسک زمانی مخصوص هر افق h ساختیم. یعنی برای هر h از ۱ تا ۷ گفتیم:

آخرین روزی که می تونه تو train باشه، باید h روز قبل از شروع val تموم بشه، و همین طور برای val و test هم مرزها رو عقب کشیدیم. این کار باعث شد هیچ وقت "y" آینده از بیرون بازه خودش وارد آموزش نشه. این دقیقاً همون کاریه که خیلی ها انجام نمی دن و بعد متوجه نمی شن چرا نتایج شون الکی خوبه.

حالا اصل داستان: ما برای هر افق h ۱ تا ۷ روز آینده اومدیم y رو با shift(-h) ساختیم. یعنی اگر امروز ۰۱-۰۶-۲۰۱۵ باشه و h=3 باشه، لیبِل میشه فروش ۳ روز بعد. بعد ردیف هایی که y ندارن (نزدیک انتهای سری) حذف شدن و X و y آماده شد. تو خروجی هم دقیقاً می بینی که با زیاد شدن h تعداد نمونه ها کم میشه، چون هر چی افق جلوتر میره، ته سری ها لیبِل ندارن و باید بریزن بیرون. این طبیعیه و درست هم هست.

مدلی که برای multi-step استفاده کردیم "Quantile Regression" بود، آن هم از صفر با گرادیان دیسنت. یعنی برای هر h سه مدل جدا ساختیم: یکی برای (p10)۰.۱، یکی برای (p50)۰.۵، یکی برای (p90)۰.۹. همون پیش بینی مرکزیه (مثل median)، و p10/p90 بازه ای میدن که می تونه نقش عدم قطعیت رو بازی کنه. اینجا به جای loss معمولی، از pinball loss استفاده شد که مخصوص کوانتایل هاست.

بعد از اینکه برای هر افق مدل ها آموزش داده شدن، برای validation چند تا چیز رو حساب کردیم:

RMSPE, RMSE, MAPE و R2 برای p50، و pinball loss برای هر کوانتایل.

بعد هم دو تا شاخص خیلی مهم مربوط به uncertainty رو حساب کردیم:

یکی coverage یعنی چند درصد از y واقعی داخل بازه p10 تا p90 افتاده، و یکی width یعنی میانگین پهنای بازه (p90-p10) چقدره.

اینجا دقیقاً به مشکل مهم تو نتایج دیده میشه که تو اسکرین شات هم خیلی واضح هست coverage: برای بازه p10-p90 تقریباً صفر شده. یعنی چی؟ یعنی مدل های کوانتایل به شکلی آموزش دیدن که p10 و p90 درست "دور" y رو نگرفتن، یا حتی بدتر، احتمالاً ترتیب کوانتایل ها خراب شده (مثلاً p10 از p90 بزرگ تر شده یا برعکس)، یا scale/log handling به جا اشتباه شده و خروجی ها به شکل معناداری از y پرت شدن. چون coverage=0.0 برای همه horizon ها واقعاً نشونه اینه که uncertainty ما از نظر کالیبراسیون بد دراومده و بازه ها اصلاً واقع بینانه نیستن. اینو تو گزارش به عنوان "چالش/ایراد مشاهده شده" می نویسیم، نه اینکه پنهانش کنیم، چون اتفاقاً خیلی هم حرفه ایه که بگی اینجا کالیبراسیون interval درست نشد و دلایلش رو حدس بزنی.

یه نشونه دیگه هم تو جدول هست val_rmsep50: تقریباً ۱ شده و R2 منفی خیلی بزرگه. این هم یعنی پیش‌بینی‌های p50 از نظر مقیاس یا برگشت از log، درست نمی‌نشینن. چون اگر مدل یه چیز خیلی پرت بده، RMSPE میره نزدیک ۱ یا بالاتر، و R2 منفی میشه. پس برداشت گزارش این میشه که “مدل quantile خطی برای multi-step تو این پیاده‌سازی، مثل XGBoost موفق نبود و احتمالاً به خاطر ضعف مدل خطی/هایپر پارامترها یا مشکل در پیاده‌سازی scale/log، خروجی‌ها کالیبره نشدن.”

ولی با این حال، از نظر ساختار پروژه، پیاده‌سازی فاز ۴ دقیق و درست طراحی شده: مدل برای هر افق جداست، leakage کنترل شده، و هم خروجی متریک و هم نمودارها ذخیره شدن. یعنی فریم‌ورک درسته، فقط نتیجه مدل اینجا مثل فاز ۳ خوب نشده.

بعد از بخش کوانتایل، ما یک “جدول پیش‌بینی نمونه” هم ساختیم. یعنی از یک تاریخ مبدا (یک روز قبل از شروع test) رفتیم برای چند فروشگاه تصادفی، برای هر کدام فروش ۱ تا ۷ روز آینده رو با p10/p50/p90 نوشتیم و تو forecast_sample_next_horizons.csv ذخیره کردیم. این بخش خیلی شبیه چیزیه که تو واقعیت به مدیر می‌دن: می‌گه برای فروشگاه X، فردا حدوداً اینه، بدبینانه اینه، خوشبینانه اینه.

بعد رفتیم سراغ عدم قطعیت با ensemble. ایده‌اش این بود که به جای اینکه مستقیم از p10/p90 استفاده کنیم، چندتا مدل median جدا آموزش بدیم (K=7) تا با seed متفاوت، بعد روی validation ببینیم پراکندگی پیش‌بینی‌ها چقدره. از روی میانگین و std اون‌ها یک بازه‌ی تقریبی ۹۰٪ ساختیم (با $z \approx 1.6449$). اینجا هم خروجی مهمش coverage_approx90 بود. تو اسکرین‌شات می‌بینیم coverage حدود 0.172 بوده، یعنی خیلی کمتر از 0.90. این یعنی حتی ensemble هم بازه‌ها رو درست کالیبره نکرده و uncertainty خیلی کم‌عرض بوده یا خطا زیاد بوده. خلاصه نتیجه این میشه که “عدم قطعیت تولید شد، اما کالیبراسیون ضعیف بود و نیاز به تنظیم دارد.”

حالا بخش آخر و جذاب‌تر: طبقه‌بندی فروش.

اینجا گفتیم به جای اینکه عدد دقیق فروش رو بگیریم، فروش رو سه کلاس کنیم: Low / Medium / High: برای اینکه کلاس‌ها بالانس باشن، آستانه‌ها رو از داده train برداشتیم: یک‌سوم پایین (t1) و دوسوم پایین (t2) یعنی تقریباً هر کلاس یک‌سوم داده‌ها رو می‌گیره. این باعث میشه مدل طبقه‌بندی با مشکل imbalance شدید مواجه نشه.

این طبقه‌بندی رو برای دو افق انجام دادیم h=1 و h=7. یعنی هم فروش فردا رو کلاس‌بندی کردیم، هم فروش ۷ روز بعد رو.

مدل هم یک softmax regression بود که باز از صفر با GD پیاده‌سازی شده. بعد با دو معیار اصلی ارزیابی کردیم F1-macro و ROC-AUC (OvR macro). تو نتایج (طبق جدول اسکرین‌شات) برای h=1، روی validation F1 حدود 0.72 و روی test F1 حدود 0.78 شده و AUC هم بالاست (حدود 0.88 تا 0.93). برای h=7 هم حتی بهتره F1 test: حدود 0.815 و AUC test حدود 0.944. این یعنی با اینکه مدل رگرسیون چندگامی (کوانتایل) خوب درنیومده، ولی طبقه‌بندی سطح فروش خیلی خوب جواب داده. یعنی مدل می‌تونه تشخیص بده فروش اون روز “کم” یا “متوسطه” یا “زیاده” حتی اگر عدد دقیقش رو خیلی دقیق نزنه.

در آخر هم خروجی‌ها کامل ذخیره شدن داخل artifacts/phase4/ شامل متریک‌ها، نمودار RMSPE نسبت به افق، نمودار coverage، نمودار width، جدول پیش‌بینی نمونه، متریک‌های ensemble و همین‌طور confusion matrix های val/test برای h=1 و h=7.

جمع‌بندی خیلی خودمونی فاز ۴ اینه: ما یک سیستم کامل ساختیم که برای هر فروشگاه بتونه ۱ تا ۷ روز آینده رو پیش‌بینی کنه و حتی بازه اطمینان بده. از نظر طراحی و ضد لیک بودن، کار تمیزه و درست انجام شده. اما نتایج قسمت quantile و uncertainty نشون داد که این

مدل خطی کوانتایل تو این اجرا خوب کالیبره نشده و coverage ها افتضاح شده (تقریباً صفر). در مقابل، بخش طبقه‌بندی خیلی خوب جواب داده و برای تصمیم‌گیری سطحی (کم/متوسط/زیاد) عملکرد قوی داشته.

فاز پنجم - Deep

اول کاری که کردیم این بود که خروجی‌های فاز ۲ رو لود کردیم `train_features`، `val_features`، `test_features` و لیست ستون‌های فیچر رو از `feature_cols.json` گرفتیم. مثل فازهای قبل به چک جدی گذاشتیم که ستون `Store` توی `feature_cols` نباشه. چون `Store` فقط ID هست و اگر بیاد تو مدل، مدل ممکنه به جای یاد گرفتن الگو، صرفاً فروشگاه‌ها رو حفظ کنه یا وزن عجیب بهش بده. پس `Store` رو از فیچرها حذف کردیم و تارگت هم همون `Sales` بود که (طبق فاز ۲) به شکل `log1p` ذخیره شده.

حالا تفاوت اصلی دیپ‌لرنینگ با مدل‌های قبلی اینه که اینجا مدل انتظار داره به جای یک ردیف مستقل، "یه دنباله از روزهای پشت‌سرهم" رو ببینه. برای همین ما به `Sliding Window` ساختیم. یعنی گفتیم `LOOK_BACK = 14`، پس برای هر فروشگاه، میایم ۱۴ روز گذشته رو به عنوان ورودی `X` می‌دیم و فروش روز بعدش رو به عنوان `y` می‌گیریم. این کار رو فروشگاه‌به‌فروشگاه انجام دادیم که دیتای دو فروشگاه قاطی نشه. این خیلی مهمه چون اگر ردیف‌ها رو همینجوری پشت‌هم بذاری، ممکنه انتهای فروشگاه ۱ و ابتدای فروشگاه ۲ کنار هم بیفتن و مدل فکر کنه اینا ادامه هم هستن! برای همین ما `groupby(Store)` زدیم، تاریخ رو سورت کردیم، بعد توی هر فروشگاه جداگانه پنجره‌های ۱۴ تایی ساختیم.

پس خروجی این مرحله این شد که `X_train` و `X_val` و `X_test` به شکل سه‌بعدی ساخته شدن:

تعداد نمونه‌ها، ۱۴، تعداد فیچرها

یعنی هر نمونه دقیقاً یک "سکانس ۱۴ روزه از فیچرها" بود.

بعد رفتیم سراغ ساخت دو مدل:

1. LSTM

`LSTM` رو به شکل ساده ساختیم: یک لایه `LSTM` با `units` قابل تنظیم، بعد `Dropout` برای جلوگیری از `overfitting`، بعد یک `Dense 64` با `ReLU`، و در آخر `Dense(1)` برای خروجی عددی `Loss`. هم `MSE` گذاشتیم و `optimizer` هم `adam`. این معماری خیلی پیچیده نیست، ولی برای پروژه دانشگاهی کاملاً استاندارد و قابل دفاعه.

2. TCN در عمل یک مدل Conv1D ساده

اینجا به مدل کانولوشنی ساختیم `Conv1D`: با فیلتر ۶۴ و کرنل ۲، بعد `MaxPooling`، بعد `Flatten`، و `Dense`. حقیقتش این معماری بیشتر `CNN` "روی سری زمانی" حساب میشه تا `TCN` واقعی، ولی از نظر ایده، همون داستان رو داره: با کانولوشن روی زمان، الگوهای کوتاه‌مدت رو می‌گیره و سریع‌تر از `LSTM` هم می‌تونه یاد بگیره.

بعدش نوبت `Optuna` شد. ما کد `Optuna` رو گذاشتیم که بتونه `units` و `dropout` رو برای `LSTM` تیون کنه. یعنی اگر `RUN_OPTUNA=True` می‌شد، با چند تا `trial` مدل رو می‌ساخت، چند `epoch` سریع آموزش می‌داد، و `val_loss` رو معیار انتخاب می‌گرفت. حتی `early stopping` هم گذاشتیم که زمان الکی تلف نشه.

ولی چون این پروژه اگر Optuna روشن می شد ممکن بود طولانی بشه، RUN_OPTUNA رو False گذاشتیم و گفتیم پارامترها رو از قبل یک مقدار مناسب انتخاب می کنیم units=64 و dropout=0.2. این همون چیزیه که تو خروجی هم ثبت شده.

بعد از مشخص شدن پارامترها، هر دو مدل رو نهایی آموزش دادیم. هر کدوم ۱۰ epoch با batch_size=256 و validation_data اجرا شدند. یعنی مدل ها همزمان روی val کنترل می شدن که خیلی overfit نکنن.

بعد رسیدیم به ارزیابی روی test. اینجا چون y ها log هستند، ما هم y_test رو expm1 کردیم هم پیش بینی ها رو expm1 کردیم تا همه چیز برگرده به مقیاس واقعی یورو. بعد RMSE و RMSPE رو حساب کردیم RMSPE. رو هم فقط روی جاهایی حساب کردیم که $y_{true} > 0$ باشد تا تقسیم بر صفر پیش نیاد.

نتایج دقیقاً طبق خروجی که فرستادی این بود:

• LSTM
RMSE = 3631.13 یورو

RMSPE = 0.4835

• TCN
RMSE = 2489.15 یورو

RMSPE = 0.3768

تو این پیاده سازی، مدل TCN از LSTM بهتر جواب داده. یعنی هم خطای مطلقش کمتره (RMSE پایین تر)، هم درصد خطاش بهتره (RMSPE پایین تر). این اتفاق هم خیلی عجیب نیست؛ چون تو Rossmann، خیلی وقتا مدل های کانولوشنی ساده یا مدل های درختی (مثل XGB از LSTM بهتر عمل می کنن، مخصوصاً وقتی داده tabular زیادی داریم و سکانس ها خیلی بلند نیستن LSTM. معمولاً وقتی خیلی خوب میشه که سری زمانی "واقعاً" sequence-heavy باشه و features خیلی تمیز و پیوسته باشن و مدل هم زمان کافی برای تیون داشته باشه.

بعد از این، یک نمودار مقایسه ای هم کشیدیم برای آخرین ۱۰۰ نمونه تست: خط واقعی فروش با خط چین مشکی، و دو خط پیش بینی برای LSTM و TCN. این نمودار خیلی به درد گزارش می خوره چون مصحح می بیند مدل ها چقدر trend رو می گیرن و چقدر lag دارن.

حالا بخش جذاب بعدی SHAP :

اینجا هدف این بود که فقط نگیم "مدل فلان خطا رو داد"، بلکه به ذره هم توضیح بدیم "چرا این پیش بینی رو کرده؟ به چی نگاه کرده؟". چون مدل های عمیق معمولاً black-box هستن. برای همین از KernelExplainer SHAP استفاده کردیم. ولی چون SHAP برای deep model خیلی سنگینه، اومدیم یک نمونه کوچک برداشتیم (۲۰ تا نمونه از X_test، بعد اون رو reshape کردیم به ۲ بعدی (چون SHAP اینجا با ورودی ۲ بعدی راحت تر کار می کنه)، و یک wrapper نوشتیم که دوباره این ۲ بعدی رو به ۳ بعدی تبدیل کنه و بده به model.predict.

برای اینکه SHAP سریع تر بشه، از shap.kmeans برای ساختن background استفاده کردیم (۱۰ مرکز). همون warning های قرمز تو اسکرین شات هم از همین قسمت میاد sklearn: یکی مینز روی MKL یه هشدار مربوط به thread ها میده که خیلی جدی نیست، بیشتر یه warning سیستمیه و روی نتیجه تاثیر خاصی نداره. مهم اینه که SHAP اجرا شده و خروجی ها ذخیره شده.

در نهایت دو تا SHAP plot ذخیره شد: یکی برای LSTM و یکی برای TCN. اینا به شکل summary plot نشون میدن کدوم فیچرها به طور کلی بیشتر اثر گذاشتن. فقط یه نکته: چون ما ورودی رو flatten کردیم (۱۴ روز × تعداد فیچرها)، اگر اسم فیچرها رو دقیق نگذاشته باشیم، SHAP ممکنه ستون‌ها رو با شماره نشون بده یا خیلی خوانا نباشه. ولی برای گزارش همین که “feature importance” رو نشون بدیم و بگیم مدل روی چه چیزهایی حساسه، کافی و قابل دفاعه.

آخر کار هم یک فایل metrics_deep_learning.csv ذخیره کردیم. نکته جالب اینجا اینه که به خاطر یک باگ ImportError یا مشکل pandas.to_csv در محیط، از مازول استاندارد csv استفاده شد تا خروجی متریک‌ها حتماً ذخیره بشه. این هم یه نکته مثبت تو گزارشه: یعنی پروژه رو مقاوم کردیم که وسط باگ محیطی زمین نخوره.